

## 1 Einführung

### Nutzen ComBau

- Programmiersprachen und Sprachkonzepte besser verstehen
- Sprachfeatures beurteilen können
- Konzepte in verwandten Bereichen einsetzen

### 1.1 Begriffe

#### Compiler

- Transformiert Quellcode in Maschinencode

#### Runtime System

- Unterstützt die Programmausführung mit Software und Hardware Mechanismen

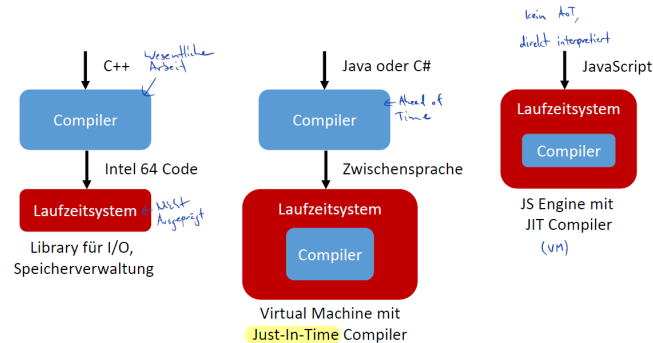
#### Syntax

- Definiert Struktur des Programms
- Bewährte Formalismen für Syntax

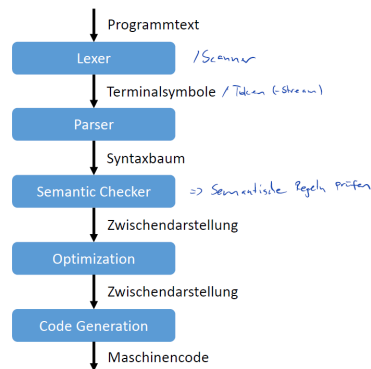
#### Semantik

- Definiert Bedeutung des Programms
- Meist in Prosa beschrieben

### 1.2 Architekturen



### 1.3 Aufbau Compiler



#### 1.3.1 Lexer

##### Lexikalische Analyse, Scanner

- Zerlegt Programmtext in Terminalsymbole (Tokens)
- keine Tiefenstruktur

#### 1.3.2 Parser

##### Syntaktische Analyse

- Erzeugt Syntaxbaum gemäss Programmstruktur
- Kontextfreie Sprache

#### 1.3.3 Semantic Checker

##### Semantische Analyse

- Löst Symbole auf
- Prüft Typen und semantische Regeln

#### 1.3.4 Optimization

- Wandelt Zwischendarstellung in effizientere um

#### 1.3.5 Code Generation

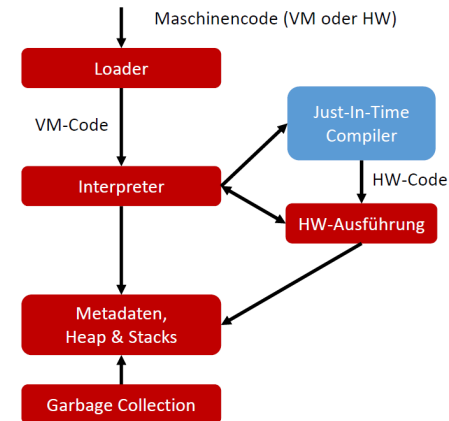
- Erzeugt ausführbarer Maschinencode

#### 1.3.6 Zwischenartstellung

##### Intermediate Representation

- Beschreibt Programm als Datenstruktur (diverse Varianten)

#### 1.4 Aufbau Laufzeitsystem



#### 1.4.1 Loader

- Lädt Maschinencode in Speicher
- Veranlasst Ausführung

#### 1.4.2 Interpreter

- Liest Instruktionen und emuliert diese in Software

#### 1.4.3 JIT (Just-In-Time) Compiler

- Übersetzt Code-Teile in Hardware-Instruktionscode

#### 1.4.4 HW-Ausführung (nativ)

- Lässt Instruktionscode direkt auf HW-Prozessor laufen

#### 1.4.5 Metadaten, Heap + Stacks

- Merken Programminfos, Objekte und Prozeduraufrufe

#### 1.4.6 Garbage Collection

- Räumt nicht erreichbare Objecte ab

Extended Backus-Naur Form

Produktion (Syntaxregel)

Expression = "(" ")" | "(" Expression ")".

Nicht-Terminal-Symbol (NTS)

kommen im End-Resultat nie vor, werden weiter aufgelöst.

Terminalsymbol in "" / Token

	Beispiel	Sätze
Konkatenation	"A" "B"	"AB"
Alternative	"A"   "B"	"A" oder "B"
Option	[ "A" ]	leer oder "A"
Wiederholung	{ "A" }	leer, "A", "AA", "AAA", etc.

meist EBNF aus  $\rightarrow$  anders als andere Formen

Runde Klammern für stärkere Bindung.  
 | bindet schwächer als andere Konstrukte.

Links - Rekursiv

Präzedenz: \* bindet stärker als +

Expression = Term | Expression "+" Term.

Term = Variable | Term "\*" Variable.

Variable = "a" | "b" | "c" | "d".

Linksassoziativität für a + b + c bzw. a \* b \* c

## 2 Lexikalische Analyse

### 2.1 Lexer / Scanner

#### Endlicher Automat (DEA)

- Kümmt sich um die lexikalische Analyse
- Input: Zeichenfolge (Programmtext)
- Output: Folge von Terminalsymbolen (Tokens)

#### 2.1.1 Aufgaben

- Fasst Textzeichen zu tokens zusammen
- Eliminiert Whitespaces
- Eliminiert Kommentare
- Merkt Positionen in Programmcode

#### 2.1.2 Nutzen

#### Abstraktion

- Parser muss sich nicht um Textzeichen kümmern

#### Einfachheit

- Parser braucht Lookahead pro Symbol, nicht Textzeichen

#### Effizienz

- Lexer benötigt keinen Stack im Gegensatz zu Parser

### 2.2 Tokens

#### Statisch (Keywords, Operationen, Interpunktion)

- *if*
- *else*
- *while*
- *\**
- *%%*
- *;*

#### Identifiers


- MyClass
- readFile
- name2

#### Zahlen

- 123
- 0xfe12
- 1.2e-3

#### Strings

- "Hello"
- ""
- "\n"



#### 2.2.1 Lexem

- Spezifische Zeichenfolge, die einen Token darstellt
- z.B. *MyClass* ist ein Lexem des Tokens Identifier

#### 2.2.2 Maximum Munch

- Lexer absorbiert möglichst viel in einem Token

### 2.3 Reguläre Sprachen

- Lexer unterstützt nur reguläre Sprachen
- **Regulär**: Als EBNF ohne Rekursion ausdrückbar

Integer = Digit { Digit }.  
Digit = "0" | ... | "9".

Regulär

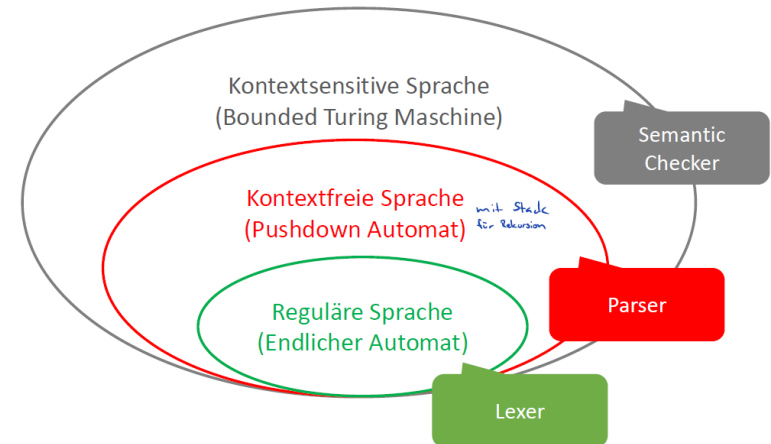
⇒ nicht rekursiv

Ausdruck = [ "(" Ausdruck ")" ].

Nicht regulär

⇒ rekursiv nötig

### 2.4 Chomsky Hierarchie



### 2.5 Lexer Gerüst

```
class Lexer {
    private final Reader reader;
    private char current; // one Character Lookahead
    private boolean end; // EOF

    private Lexer(Reader reader) {
        this.reader = reader;
    }

    public static Iterable<Token> scan(Reader reader) {
        return new Lexer(reader).readTokenStream();
    }

    // ...
}
```

### 2.6 Token Stream lesen

```
Iterable<Token> readTokenStream() {
    var stream = new ArrayList<Token>();
    readNext(); // One Character Lookahead
    skipBlanks();
    while (!end) {
        stream.add(readToken());
        skipBlanks();
    }
    return stream;
}
```

### 2.7 Lexer Kernlogik

```
Token readToken() {
    if (isDigit(current)) {
        return readInteger();
    }
    if (isLetter(current)) {
        return readName(); // Identifier / Keyword
    }
    return switch (current) {
        case '"': readString();
        case '+': readStaticToken(Tag.Plus);
        case '-': readStaticToken(Tag.Minus);
        case '/': readPotentialSlash();
    }
}
```

#### 2.7.1 Static Token scannen

```
StaticToken readStaticToken(Tag tag) {
    readNext();
    return new StaticToken(tag);
}
```

### 2.7.2 Zahlen scannen

#### Beachten:

- Range Check (32 bit): Integer Overflow
- $Integer.MIN = Integer.MAX + 1$

```
IntegerToken readInteger() {
    int value = 0;
    while (!_end && isDigit(current)) {
        int digit = current - '0'; // char to int
        value = value * 10 + digit; // create decimal number
        readNext();
    }
    return new IntegerToken(value);
}
```

### 2.7.3 Identifier und Keywords scannen

```
Token readName() {
    String name = Character.toString(current);
    readNext();
    while (!end & (isLetter(current) || isDigit(current))) {
        name += current;
        readNext();
    }
    if (KEYWORDS.containsKey(name)) {
        return new StaticToken(KEYWORDS.get(name));
    }
    return new IdentifierToken(name);
}
```

### 2.7.4 String scannen

#### Beachten:

- Kein `\t`
- Kein `\"`
- Kein `\n`
- Keine mehrzeiligen Strings

```
StringToken readString() {
    readNext(); // Skip leading double Quote
    String value = "";
    while (!end && current != '\''') {
        value += current;
        readNext();
    }
    if (end) {
        // Error: String not closed
    }
    readNext(); // Skip trailing double Quote
    return new StringToken(value);
}
```

### 2.7.5 Kommentare erkennen

```
StaticToken readPotentialSlash() {
    readNext();
    if (current == '/') {
        skipLineComment();
        // move on to next token
    } else if (current == '/*') {
        skipCommentBlock();
        // move on to next token
    } else {
        return new StaticToken(Tag.Divide);
    }
}
```

### 3 Parser

#### Kontextfreie Sprache

- Kümmt sich um die syntaktische Analyse
- Input: Tokens (Terminalsymbole)
- Output: Syntaxbaum / Parse Tree

#### 3.1 Aufgabe


- Finde eindeutige Ableitung der Syntaxregeln, um einen gegebenen Input herzuleiten
- Analysiert die gesamte Syntaxdefinition (mit rekursiven Regeln)
- Erkennt, ob Eingabetext Syntax erfüllt
- Erzeugt Syntaxbaum

Input:  $1 + (2 - 3)$

Ableitung: Expression  
Term "+" Term  
Number "+" Term  
Number "+" "(" Expression ")"  
Number "+" "(" Term "-" Term ")"  
Number "+" "(" Number "-" Term ")"  
Number "+" "(" Number "-" Number ")"


#### 3.2 Parse Tree

- Concrete Syntax Tree
- Ableitung der Syntaxregeln als Baum wiedergespiegelt
- Kann generiert werden



#### 3.2.1 Abstract Syntax Tree

- Unwichtige Details auslassen
- Struktur vereinfacht
- Für Weiterverarbeitung massgeschneidert
- Eigendesign nach Gusto des Compiler-Entwicklers
- Nur mit Selbstimplementation möglich



#### 3.3 Parser Strategien

##### 3.3.1 Top-Down

- Beginne mit Start-Symbol
- Wende Produktionen an

- Expandiere Start-Symbol auf Eingabetext
- $Expr \rightarrow Term + Term \rightarrow \dots \rightarrow 1 + (2 - 3)$

Input:  $1 + (2 - 3)$

Ableitung: Expression  
Term "+" Term  
Number "+" Term  
Number "+" "(" Expression ")"  
Number "+" "(" Term "-" Term ")"  
Number "+" "(" Number "-" Term ")"  
Number "+" "(" Number "-" Number ")"

Top-Down

linksseitig expandieren

##### 3.3.2 Bottom-Up

- Beginne mit Eingabetext
- Wende Produktionen an
- Reduziere Eingabetext auf Start-Symbol
- $Expr \leftarrow -Term + Term \leftarrow \dots \leftarrow -1 + (2 - 3)$

Input:  $1 + (2 - 3)$

Ableitung: Expression  
Term "+" Term  
Term "+" "(" Expression ")"  
Term "+" "(" Term "-" Term ")"  
Term "+" "(" Term "-" Number ")"  
Term "+" "(" Number "-" Number ")"  
Number "+" "(" Number "-" Number ")"

Bottom-Up

rechtsseitig reduzieren

##### 3.4 Recursive Descent

- Pro Nicht-Terminalsymbol eine Methode
  - Implementiert die Erkennung gemäss EBNF-Produktion
- Vorkommen eines Nicht-Terminalsymbols in Syntax
  - Aufruf der entsprechenden Methode
- Funktioniert bei rekursiven und nicht-rekursiven Produktionen

```
void parseExpression() {
    parseTerm();
    // ...
}
void parseTerm() {
    parseExpression();
    // ...
}
```

##### 3.5 Parser Gerüst

```
public class Parser {
    private final Iterator<Token> tokenStream;
    private Token current; // One Token Lookahead

    private Parser(Iterable<Token> tokenStream) {
        this.tokenStream = tokenStream.iterator();
    }

    public static ProgramNode parse(Iterable<Token> stream) {
        return new Parser(stream).parseProgram(); // Aufbasierte Klasse
    }
}
```

##### 3.5.1 Parser-Einstieg

Program = Expression

```
private ProgramNode parseProgram() {
    var classes = new ArrayList<ClassNode>();
    parseExpression();
    while (!isEnd()) {
        next();
        classes.add(parseClass());
    }
    return new ProgramNode(classes);
}
```

```
}
```

### 3.5.2 Expression

*Expression = Term(" + "|" - ")Term*

```
Expression parseExpression() {
    var left = parseTerm();
    while(is(Tag.PLUS) || is(Tag.MINUS)) {
        var op = is(Tag.PLUS) ? Operator.PLUS : Operator.MINUS;
        next();
        var right = parseTerm();
        var left = new BinaryExpression(op, left, right);
    }
    return left;
}
```

```
}
```

### 3.5.3 Term

*Term = Number|"(" Expression")"*

```
Expression parseTerm() {
    if(isInteger()) {
        int value = readInteger();
        next();
        return new IntegerLiteral(value);
    } else if (is(Tag.OPEN_PARENTHESIS)) {
        next();
        var expression = parseExpression();
        if(is(Tag.CLOSE_PARENTHESIS)) {
            next();
        } else {
            error(); // missing closed parenthesis
        }
        return expression();
    } else {
        error(); // missing open parenthesis
    }
}
```

```
}
```

## 3.6 One Symbol Lookahead

### Statement

*Assignment|IfStatement*

- Bestimme mögliche Terminalsymbole, die mit einer Produktion ableitbar sind (FIRST-Menge)
- Benutze FIRST zur Entscheidung der Alternative beim zielorientierten Parsen

```
void parseStatement() {
    if(isIdentifier()) { // FIRST(Assignment)
        parseAssignment();
    } else if(is(Tag.IF)) { // FIRST(IfStatement)
        parseIfStatement();
    } else {
        error();
    }
}
```

```
}
```

## 3.7 Technische Syntax-Umformung

- Falls 1 Lookahead nicht reicht

```
Statement = Assignment | Invocation
Assignment = Identifier "=" Expression
Invocation = Identifier "(" " ")"
```

↓

```
Statement = Identifier (AssignmentRest | InvocationRest)
AssignmentRest = "=" Expression
InvocationRest = "(" " ")"
// Lookahead 1 reicht wieder
```

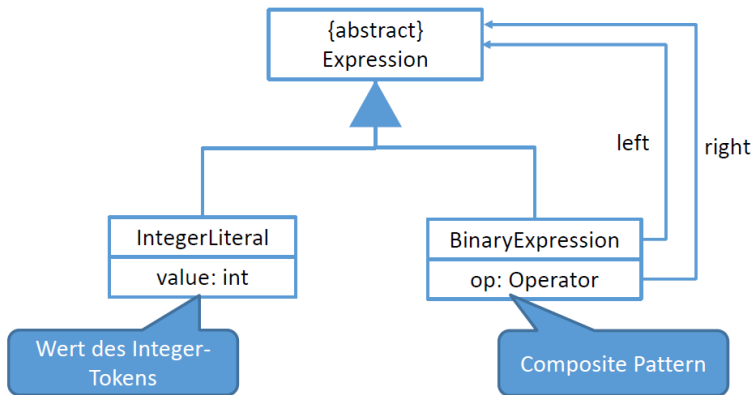
### 3.7.1 Code Beispiel

```
var parseStatement() {
    var identifier = readIdentifier();
    next();
    if (is(Tag.ASSIGN)) {
        parseAssignmentRest(identifier);
    } else if (is(Tag.OPEN_PARENTHESIS)) {
        parseInvocationRest(identifier);
    } else {
        error();
    }
}
```

```
}
```

## 4 Parser Vertiefung

### 4.1 Abstrakter Syntaxbaum Design



### 4.2 Bottom-Up Parsing

- Mächtiger als LL (Top-Down) Parser
- Kann Linksrekursion behandeln

#### Top-Down Parser (LL)

Input: 1 + ( 2 - 3 )

Ableitung: Expression  
Term + Term  
1 + Term  
1 + ( Expression )  
1 + ( Term - Term )  
1 + ( 2 - Term )  
1 + ( 2 - 3 )

↓ Top-Down

→ linksseitig expandieren

#### Bottom-Up Parser (LR)

Input: 1 + ( 2 - 3 )

Ableitung: Expression  
Term + Term  
Term + ( Expression )  
Term + ( Term - Term )  
Term + ( Term - 3 )  
Term + ( 2 - 3 )  
1 + ( 2 - 3 )

↑ Bottom-Up

← rechtsseitig reduzieren

### 4.2.1 Ansatz

- Lese Symbole im Text ohne fixes Ziel
- Prüfe nach jedem Schritt, ob gelesene Folge Produktion entspricht
  - Wenn ja: Reduziere auf Syntaxkonstrukt (REDUCE)
  - Wenn nein: Lese weiteres Symbol im Text (SHIFT)
- Am Schluss bleibt Startsymbol übrig, sonst Syntaxfehler

### 4.2.2 Beispielablauf

Schritt	Erkannte Konstrukte	Rest der Eingabe
		1 + ( 2 - 3 )
SHIFT	1	+ ( 2 - 3 )
REDUCE	Term	+ ( 2 - 3 )
SHIFT	Term +	( 2 - 3 )
SHIFT	Term + (	2 - 3 )
SHIFT	Term + ( 2	- 3 )
REDUCE	Term + ( Term	- 3 )
SHIFT	Term + ( Term -	- 3 )
SHIFT	Term + ( Term - 3	)
REDUCE	Term + ( Term - Term	)
REDUCE	Term + ( Expression	)
SHIFT	Term + ( Expression )	
REDUCE	Term + Term	
REDUCE	Expression	

### 4.2.3 Parser Tabelle - Vereinfacht

Erkannte Konstrukte	Regel
... Number	REDUCE Term
... Term + Term	REDUCE Expression
... "( Expression )"	REDUCE Term
Sonst	SHIFT

Suffix des Zustands entscheidet (Stack-Prinzip)

### 4.3 LR-Parser (Bottom-Up) Varianten

- LR(0)**
  - Parse Tabelle ohne Lookahead erstellen
  - Zustand reicht, um zu entscheiden
- SLR(k) (Simple LR)**
  - Lookahead bei REDUCE, um Konflikt zu lösen
  - Keine neuen Zustände
- LALR(k) (Look-Ahead LR)**
  - Analysiert Sprache auf LR(0)-Konflikte
  - Benutzt Lookahead bei Konfliktstellen mit neuen Zuständen
- LR(k)**
  - Pro Grammatikschritt + Lookahead ein Zustand
  - Nicht praxistauglich, zu viele Zustände

## 5 Semantic Checker

- Kimmert sich um die semantische Analyse
- Input: Syntaxbaum
- Output: Zwischendarstellung (Syntaxbaum + Symboltabelle)

### 5.1 Semantische Prüfung

#### Deklarationen

- Jeder Identifier ist eindeutig deklariert

#### Typen

- Typregeln sind erfüllt

#### Methodenaufrufe

- Argumente und Parameter sind kompatibel

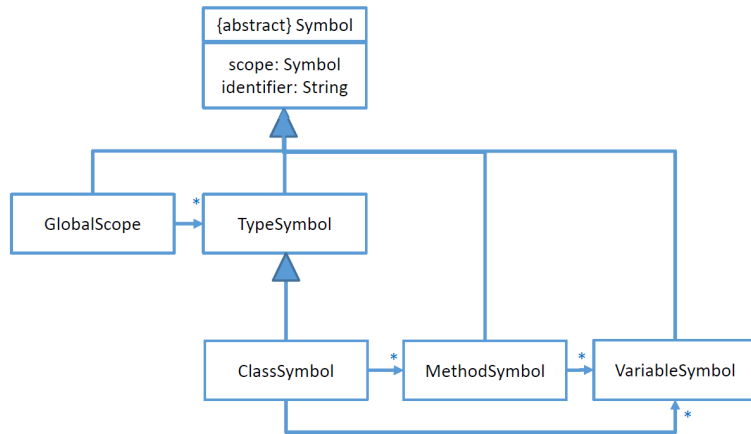
#### Weitere Regeln

- z.B. keine zyklischen Vererbung
- nur eine main() Methode

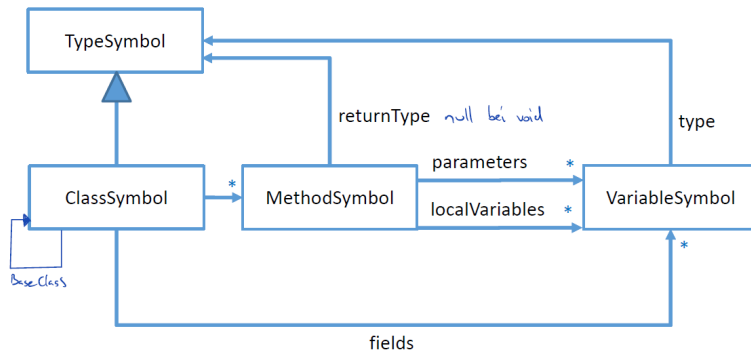
### 5.2 Symboltabelle

- Datenstruktur zur Verwaltung der Deklarationen
- Widerspiegelt hierarchische Bereiche im Programm

#### 5.2.1 Design



#### 5.2.2 Detailliertere Beziehungen



#### 5.2.3 Design Aspekte

##### Typinfo für Variable-Symbol

- Zuerst unaufgelöst (Identifier)

##### Weitere Infos

- Klassen: Basisklasse


##### Lokale Variablen

- Deklarationsbereich merken (Statements)

##### Erweitertes Typ-Design

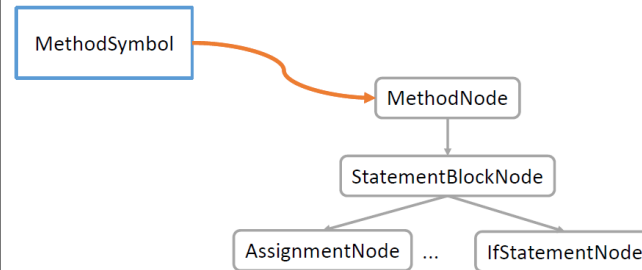
- Klassen
- Basistypen (int, boolean, string)
- Arrays

## Erweitertes Variablen-Design:



### 5.2.4 AST Verknüpfung

- Symboltabelle enthält Mapping Symbol → AST
- Für alle Deklarationen



```
node = symbolTable.getDeclarationNode(symbol)
```

### 5.3 Global Scope

- Mehrere Klassen im Programm

### 5.4 Shadowing

- Deklarationen in inneren Bereichen verdecken gleichnamige von äusseren Bereichen
- Hiding: Bei gleicher Member-Name bei Vererbung

### 5.5 Vorgehen

1. Konstruktion der Symboltabelle
2. Typen in Tabelle auflösen
3. Deklaration in AST auflösen
4. Typen in AST auflösen

#### 5.5.1 1. Konstruktion der Symboltabelle

##### AST traversieren

- Beginne mit Global Scope
- Pro Klasse, Methode, Parameter, Variable: Symbol in übergeordnetem Scope einfügen
- Explizit und/oder mit Visitor

##### Forward-Referenzen → Typ-Namen und Designatoren noch nicht auflösen!

- Da vlt noch nicht alle Klassen in der Symboltabelle sind

#### 5.5.2 2. Typen in Tabelle auflösen

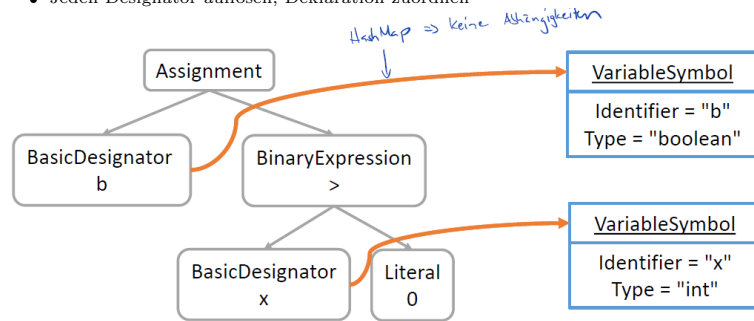
- Für Variablentyp, Parametertyp, Rückgabotyp etc.
- Brauche Suche für Identifier auf Symboltabelle
  - Starte mit innerstem Scope
  - Suche stetig nach aussen ausbreiten
  - Zuletzt in Global Scope suchen, ansonsten nicht vorhanden

```
Symbol find(Symbol scope, String identifier) {
    if(scope == null) {
        return null; // nicht im global scope
    }
    for (Symbol declaration : scope.allDeclarations()) {
        if(declaration.getIdentifer().equals(identifier)) {
            return declaration;
        }
    }
    return find(scope.getScope(), identifier); // rekursiv in nächst höheren Bereich
}
```



### 5.5.3 3. Deklaration in AST auflösen

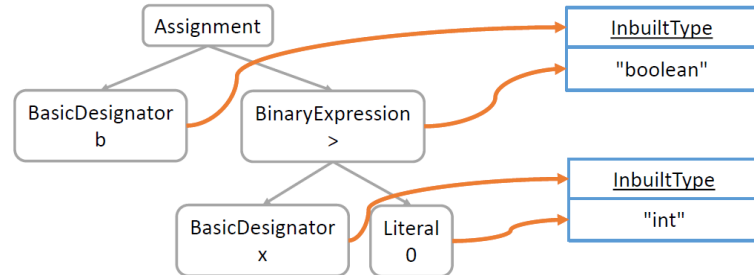
- Traversiere Ausführungscode in AST
- Jeden Designator auflösen, Deklaration zuordnen



### 5.5.4 4. Typen in AST bestimmen

#### Typ zu jeder Expression zuordnen

- Literal: definierter Typ
- Designator: Typ der Deklaration
- Unary/BinaryExpression: Resultat des Operators



#### Ablauf der Typenbestimmung:

- Post-Order-Traversierung
- AST am besten nicht erweitern sondern Maps in Symboltabelle verwenden

### 5.5.5 Typauflösung per Visitor

```
@Override
public void visit(BinaryExpressionNode node) {
    Visitor.super.visit(node); // post-order travers
    var leftType = symboltable.findType(node.getLeft());
    var rightType = symboltable.findType(node.getRight());
    // ...
    switch(node.getOperator()) {
        case PLUS -> {
            checkType(leftType, globalScope.getIntType());
            checkType(rightType, globalScope.getIntType());
            symboltable.fixType(node, globalScope.getIntType());
        }
        // ...
    }
}
```

### 5.6 Semantic Checks

- Alle Designatoren beziehen sich auf Variablen/Methoden
- Typen stimmen bei Operatoren
- Kompatible Typen bei Zuweisungen
- Argumentliste passt auf Parameterliste
- Bedingungen in if, while sind boolean
- Return Ausdruck passt
- Keine Mehrfachdeklaration
- Kein Identifier ist reserviertes Keyword
- Exakt eine main() Methode
- Array length is read-only
- Kein Exit ohne Return (ausser void)
- Lesen von initialisierten Variablen
- Null-Dereferenzierung
- Ungültiger Array-Index
- Division by Zero
- Out of Memory bei new()

6 Code Generator

6.1 Aufgabe

Erzeugung von ausführbarem Maschinencode

- Input: Zwischendarstellung (Symboltabelle + AST)
- Output: Maschinencode

Mögliche Zielmaschinen

- Reale Maschine, z.B. intel 64, ARM Prozessor
- VM, z.B. JVM, .NET CLI


6.2 Unsere Zielmaschine

Kernkonzepte

- Virtueller Stack-Prozessor: keine Register
- Branch Instructions (Goto): Programmfluss steuern
- Metadaten

6.3 Stack Prozessor

- Instruktionen benutzen Auswertungs-Stack
- Keine Register wie auf echten Prozessoren




6.4 Auswertungs-Stack

- Jede Instruktion hat definierte Anzahl von Pop- und Push-Aufrufen
- Eigener Stack pro Methodenaufruf
- Stack hat unbeschränkte Kapazität

Instruktion	Bedeutung	Auswertungs-Stack
<b>ldc &lt;const&gt;</b>	Lade Konstante (int, boolean, string)	1 Push
<b>iadd</b>	Integer Addition	2 Pop, 1 Push
<b>isub</b>	Subtraktion	2 Pop, 1 Push
<b>imul</b>	Multiplikation	2 Pop, 1 Push
<b>idiv</b>	Integer Division	2 Pop, 1 Push
<b>irem</b>	Modulo	2 Pop, 1 Push
<b>ineg</b>	Integer Negation (un-)	1 Pop, 1 Push
<b>load &lt;num&gt;</b>	Lade parameter oder lokale Variable	1 Push
<b>store &lt;num&gt;</b>	Speichere Parameter oder lokale Variable	1 Pop

6.4.1 Load/Store Nummerierungen

- *this* Referenz: Index 0
- Danach, *n* **Parameters**: Index 1..*n*
- Danach, *m* **lokale Variablen**: Index *n* + 1..*n* + *m*



6.4.2 Compare-Instruktionen

Instruktion	Bedeutung
<b>cmpeq</b>	Compare Equal (verschiedene Typen)
<b>cmpne</b>	Compare Not Equal (verschiedene Typen)
<b>icmpgt</b>	Integer Compare Greater Than
<b>icmpge</b>	Integer Compare Greater Equal
<b>icmplt</b>	Integer Compare Less Than
<b>icmple</b>	Integer Compare Less Equal

Pop right, Pop left, Push boolean

6.4.3 Branch-Instruktionen

Instruktion	Bedeutung	Auswertungs-Stack
<b>goto &lt;label&gt;</b>	Branch (bedingungslos)	-
<b>if_true &lt;label&gt;</b>	Branch falls true	1 pop
<b>if_false &lt;label&gt;</b>	Branch falls false	1 pop

6.4.4 Metadaten

- Zwischensprache kennt alle Informationen zu
  - Klassen (Namen, Typen der Fields und Methoden)
  - Methoden (Namen, Parametertypen und Rückgabetyt)
  - Lokale Variablen (Typen)
- Kein direktes Speicherlayout festgelegt
- Nicht enthalten
  - Namen von lokalen Variablen und Parameter
  - Diese sind nur nummeriert

Verwendung:

- Speicherplatz-Allozierung
- Fehlermeldungen
- Funktionsaufrufe

6.5 Code Generierung

1. Traversiere Symboltabelle: Erzeuge Bytecode Metadaten
2. Traversiere AST pro Methode (Visitor): Erzeuge Instruktionen via Bytecode Assembler
3. Serialisiere in Output Format

6.5.1 Backpatching

- Branch Offsets auflösen
- Label: relativer Instruktions-Offset ab Ende der aktuellen Branch-Instruktion

6.5.2 Template-Basierte Generierung

- Postorder-Traversierung: Kinder zuerst besuchen
- Jeweils Template für erkanntes Teilbaum-Muster anwenden


6.5.3 Short-Circuit Semantik



6.5.4 Methodenaufruf

Statisch


- Vordefinierte Methoden: `readInt()` etc.



Virtuell

- Alle anderen Methoden  
`objref.calculate(1, 2, 3);`

1. Argumente sind auf Stack (letzter zuoberst), zuunterst Objektreferenz («this»-Referenz)



2. Call-Instruktion

3. Call entfernt Argumente & Objektreferenz, legt Rückgabewert auf Stack (falls nicht void)

6.5.5 Parameter & Rückgabe

```
int sum(int x, int y) {  
    return x + y;  
}
```

```
load 1 // load param x  
load 2 // load param y  
iadd // x + y  
ret // return from method (auch bei void, max 1 Wert auf Stack)
```

7 Virtual Machine

- Hypothetische Maschine mit virtuellem Prozessor
- Eigener Instruktionssatz: Intermediate Language
  - Hülle um den realen Prozessor

- Nutzen:
- Mehrplattformen
  - Mehrsprachigkeit
  - Sicherheit

7.1 Loader


- Lädt Zwischencode (File) in Speicher
- Alloziert Speicher (Metadaten für Klassen, Methoden, Variablen, Code)
- Definiert Layouts (Speicherbereiche für Fields/Variablen/Parameter)
- Address Relocation
  - Löst Verweise auf zu Methoden, Typen, andere Assemblies
- Initiiert Programmausführung
- Optional: Verifier

7.1.1 Verifier

- Erkenne und verhindere falscher IL-Code
- Statische Analyse zur Ladezeit
  - Fehler in Compiler, böswillige Manipulationen
- Denkbare Fehler
- Typfehler
  - Stack-Überlauf oder Unterlauf
  - Nicht definierte Variablen/Methoden/Klassen
  - Illegale Sprünge

Alternative: Überprüfung zur Laufzeit

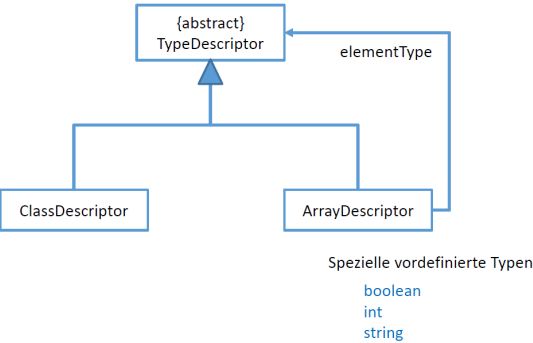
7.1.2 Metadaten



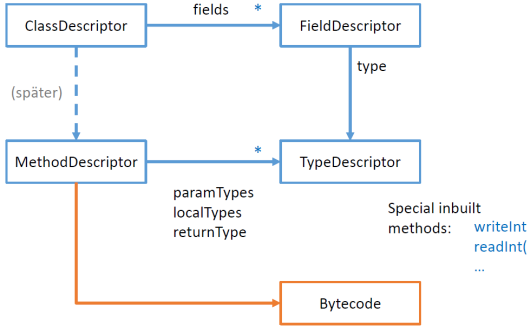
7.1.3 Deskriptoren

- Laufzeitinfo für Typen & Methoden
- Typen: Klassen, Arrays oder Basistypen
  - Klassen: Field-Typen
  - Methoden: Typen von Parameter & Locals, Rückgabety, Bytecode
  - Zusätzlich bei Klassen: Parent-Klasse, virtual Method Table

Typ-Deskriptoren



Klassen & Methoden-Deskriptoren




7.1.4 Bytecode Loading

- Von File direkt in Speicher geladen
- **Patching/Fixup:** Argumente in Instruktion anpassen
- Referenzen auf entsprechende Metadaten

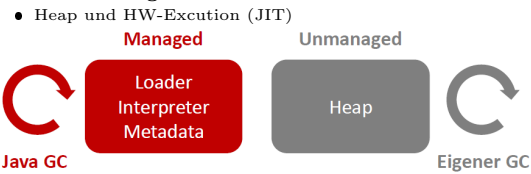
Original	Patched
invokevirtual MyMethod	invokevirtual <method_desc>
new MyClass	new <class_desc>
newarr MyType	newarr <type_desc>
getfield MyField	getfield <field_desc>
putfield MyField	putfield <field_desc>
...	

7.1.5 Patching

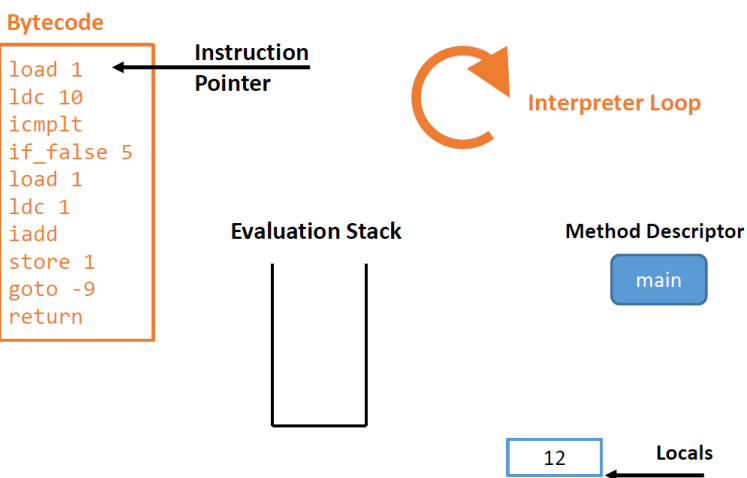


7.1.6 VM: Managed & Unmanaged

Kleine Unmanaged Teile neben der Java VM



7.2 Interpreter



7.2.1 Bestandteile

- Interpreter Loop**
- Emuliert Instruktion nach der anderen
- Instruction Pointer (IP)**
- Adresse der nächsten Instruktion
- Evaluation Stack**
- Für virtuellen Stack Prozessor
- Locals & Parameter**
- Für aktive Methoden
- Method Deskriptor**
- Für aktive Methode

## 7.2.2 Implementation

```
private void execute(Instruction instruction) {
    var operand = instruction.getOperand();
    var frame = activeFrame();
    switch (instruction.getOpCode()) {
        case LDC -> push(operand);
        case ACONST_NULL -> push(null);
        case IADD -> {
            int right = checkInt(pop());
            int left = checkInt(pop());
            push(left + right);
        }
        // ISUB, IMUL, IDIV, IREM, INEG, BNEG
        case CMPEQ -> {
            var right = pop();
            var left = pop();
            if (left != null) {
                push(left.equals(right));
            } else {
                push(left == right);
            }
        }
        // CMPNE
        case ICMP_LT -> {
            int right = checkInt(pop());
            int left = checkInt(pop());
            push(left < right);
        }
        // ICMP_LE, ICMP_GT, ICMP_GE
        case IF_TRUE -> {
            if (checkBoolean(pop())) {
                frame.setInstructionPointer(frame.getInstructionPointer() + checkInt(operand));
            }
        }
        // IF_FALSE
        case GOTO -> {
            frame.setInstructionPointer(frame.getInstructionPointer() + checkInt(operand));
        }
        case LOAD -> {
            push(getParamOrLocal(checkInt(operand)));
        }
        case STORE -> {
            setParamOrLocal(checkInt(operand), pop());
        }
        case ALOAD -> {
            var arrayIndex = checkInt(pop());
            var pointer = checkPointer(pop());
            if (pointer == null) {
                throw new InvalidBytecodeException("Null pointer");
            }
            var length = heap.getArrayLength(pointer);
            if (arrayIndex < 0 || arrayIndex >= length) {
                throw new InvalidBytecodeException("Index out of bound");
            }
            var element = heap.readElement(pointer, arrayIndex);
            push(element);
        }
        // ASTORE
        case ARRAYLENGTH -> {
            var pointer = checkPointer(pop());
            if (pointer == null) {
                throw new InvalidBytecodeException("Null pointer");
            }
            push(heap.getArrayLength(pointer));
        }
        // GETFIELD
        case PUTFIELD -> {
            var field = checkFieldDescriptor(operand);
            var index = field.getIndex();
            var value = pop();
            checkType(value, field.getType());
            var instance = checkPointer(pop());
            if (instance == null) {
                throw new InvalidBytecodeException("Accessing uninitialized object");
            }
            heap.writeField(instance, index, value);
        }
        case NEW -> {
```

```
        var type = checkClassDescriptor(operand);
        var instance = newObject(type);
        push(instance);
    }
    case NEWARRAY -> {
        var length = checkInt(pop());
        if (length < 0) {
            throw new InvalidBytecodeException("Negative array size");
        }
        var descriptor = checkArrayDescriptor(operand);
        var pointer = heap.allocateArray(descriptor, length);
        for (int i = 0; i < length; i++) {
            heap.writeElement(pointer, i, defaultValue(descriptor.getElementType()));
        }
        push(pointer);
    }
    case INSTANCEOF -> instanceofTest(operand);
    case CHECKCAST -> checkCast(operand);
    case INVOKESTATIC -> invokeStatic(operand);
    case INVOKEVIRTUAL -> invokeVirtual(operand);
    case RETURN -> returnCall();
    default -> throw new InvalidBytecodeException("Unsupported instruction opcode");
}
}
```

## 7.2.3 Prozedurale Unterstützung

### Methodenaufrufe

- invokevirtual: Aufruf neuer Methode
- return: Rücksprung aus Methode


### Activation Frame

- Datenraum einer Methode
- Parameter, lokale Variablen, temporäre Auswertungen

### Call Stack

- Stack der Activation Frames gemäss Aufrufreihenfolge
- Design:
  - Managed im Interpreter: OO Darstellung für Komfort
  - Unmanaged bei HW Execution: Kontinuierlicher Speicherblock für Effizienz

## 7.2.4 Gesamtbild



## 7.2.5 Verifikation im Interpreter

### Korrekte Benutzung der Instruktionen

- Typen stimmen (e.g. *checkInt()*)
- Methodenaufrufe stimmen (Argumente, Rückgabe etc.)
- Sprünge sind gültig
- Op-Codes stimmen

## 7.2.6 Sicherheitsmassnahmen

- Korrekter Bytecode und Typkonsistenz prüfen
- Variablen immer initialisieren (auch lokale)
- Checks durchführen (Null, Array-Index etc.)
- Stack Overflow und Underflow Detection

## 7.2.7 Interpretation vs. Kompilation

### Interpreter ist ineffizient

- Dafür flexibel und einfach zu entwickeln
- Akzeptabel für selten ausgeführten Code

### Kompilierter HW-Prozessor Code ist schneller

- Just-In-Time (JIT) Compilation für Hot Spots
- Kompilation kostet, Laufzeit macht es (allenfalls) wett

## 8 Object-Orientierung

### 8.1 Objekte zur Laufzeit

- Ablage erzeugter Objekte auf Heap
- Heap: Linearer Adressraum

Wiso werden Objekte nicht auf dem Stack angelegt?

- Sie würden Methoden-Ende nicht überleben, sondern mit Activation Frame zerstört werden.

**Objekt Lebenszeit**

- Nicht an Methodeninkarnationiion gebunden

#### 8.1.1 Deallokation

- Keine Hierarchie unter Objekten
- Keine hierarchische Lebensdauer
- Deallokation verursacht Lücken

### 8.2 Unmanaged Memory in Java

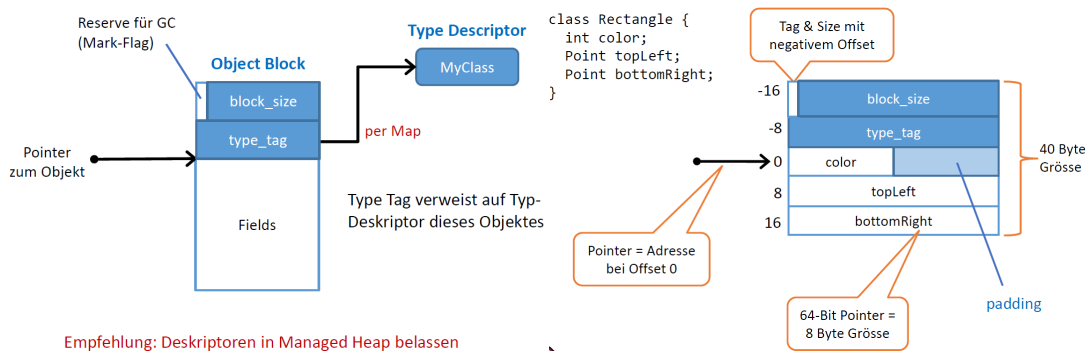
- Speicher über Java Native Access allozieren
- Raw Heap kann keine Java Referenzen speichern! Stattdessen Map verwenden (*HashMap<Long, Object>*)

```
import com.sun.jna.Memory;
```


```
Memory heap = new Memory(HEAP_SIZE);
```

```
long value = heap.getLong(address); // 64-bit lesen, address = offset im Heap
// ...
heap.setLong(address, value);
```

#### 8.2.1 Objektblock im Raw Heap



#### 8.2.2 Array Block



Einfachheit: Array-Länge durch Blockgrösse berechnen (kein Padding)

#### 8.2.3 Heap-Allokation

```
Pointer allocate(int size, TypeDescriptor type) {  
    int blockSize = size + 16; // Mit Header  
    if(freePointer + blockSize > limit) {  
        throw new VMException("Out of Memory");  
    }  
    long address = freePointer;  
    freePointer += blockSize;  
    heap.setLong(address, blockSize);  
    setTypeDescriptor(type, address);  
}
```

```
address += 16;  
return new Pointer(address);  
}
```

```
Pointer allocateObject(ClassDescriptor type) {  
    int size = type.getAllFields().length * 8; // Einfaches Layout  
    return allocate(size, type);  
}
```

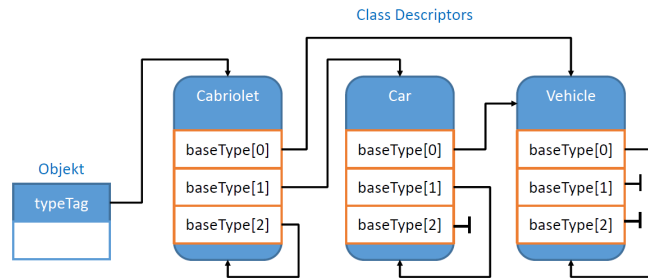
```
Pointer allocateArray(ArrayDescriptor type, int length) {  
    int size = length * 8;  
    return allocate(size, type);  
}
```

## 9 Typ Polymorphismus

### Dynamische Typ-Bestimmung

- Typ-Deskriptor = Dynamischer Typ des Objektes

#### 9.1 Ancestor Tables



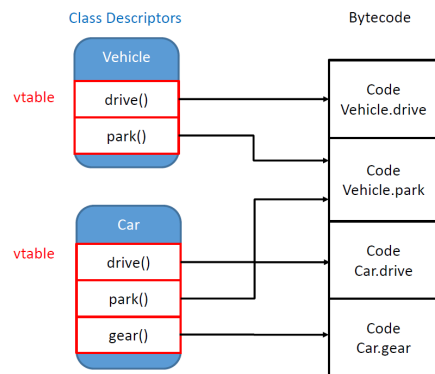
ancestor[i] = Zeiger auf Class Descriptor der Stufe i

#### 9.2 Implementierung

```
private void instanceofTest(Object operand) {
    var instance = checkPointer(pop());
    if (instance == null) {
        push(false);
    } else {
        var targetType = checkClassDescriptor(operand);
        push(typeTest(instance, targetType));
    }
}

private void checkCast(Object operand) {
    var instance = checkPointer(pop());
    push(instance);
    var targetType = checkClassDescriptor(operand);
    if (!typeTest(instance, targetType)) {
        throw new VMException("Invalid cast");
    }
}
```

#### 9.3 Virtual Method Table



##### 9.3.1 Lineare Erweiterung

#### Jede virtuelle Methode hat einen Eintrag

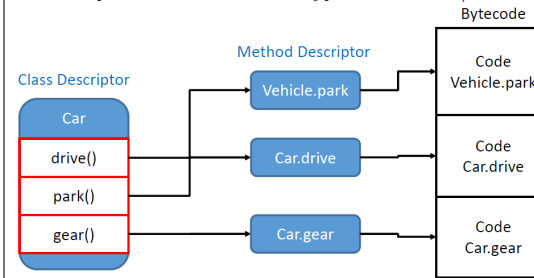
- Methoden der Basisklasse oben
- Neu deklarierte Methoden der Subklasse unten
- Funktioniert nur bei Single Inheritance

##### 9.3.2 Method Position

- Jede virtuelle Methode hat fixe Position in vtable
- Position ist statisch bekannt im deklarierten Typ

##### 9.3.3 Method Descriptor

- Zusätzliche Indirektion über Methoden-Deskriptor
- Interpreter braucht Infos zu Typen von Params/Locals




##### 9.3.4 Implementation

```
private void invokeVirtual(Object operand) {
    var staticMethod = checkMethodDescriptor(operand);
    var parameterTypes = staticMethod.getParameterTypes();
    var arguments = new Object[parameterTypes.length];
    for (int index = arguments.length - 1; index >= 0; index--) {
        arguments[index] = pop();
        checkType(arguments[index], parameterTypes[index]);
    }
    var target = checkPointer(pop());
    invokeVirtual(staticMethod, target, arguments);
}

private void invokeVirtual(MethodDescriptor staticMethod, Pointer target, Object[] arguments) {
    if (target == null) {
        throw new VMException("Null dereferenced");
    }
    var type = checkClassDescriptor(heap.getDescriptor(target));
    var position = staticMethod.getPosition();
    var vtable = type.getVirtualTable();
    var dynamicMethod = vtable[position];
    var locals = initLocals(dynamicMethod.getLocalTypes());
    if (useJIT && jitEngine.supports(dynamicMethod)) {
        performJITCall(dynamicMethod, arguments);
    } else {
        callStack.push(new ActivationFrame(dynamicMethod, target, arguments, locals));
    }
}
```

##### 9.4 Interface Support

- Interfaces global durchnummerieren
- Pro Class Descriptor eine Interface Tabelle (itable)
  - Interfaces nach Nummer = Position eintragen
- Einträge in itable verweisen auf vtable
- Class Deskriptor verweist auf itable (ibase-Pointer)



##### 9.4.1 Verzahnte Interface Tabelle

#### Grund

- Einfache Interface Tabellen sind ein Speicherproblem
- Lange itables bei vielen Interfaces
- Viele Lücken wegen globaler Nummerierung

#### Konzept


- itables im Speicher kollisionsfrei übereinanderlegen
- Muss nun prüfen, ob Eintrag für Typ gültig ist (Vermerk des Class Descriptors in vtable)

##### 9.4.2 Verschiedene Offsets

- Verzahnung auch mit verschiedenen Offsets möglich

9.4.3 Gesamtbild

Class Descriptors



Tag zur Überprüfung,  
ob Interface zu Typ passt



10 Garbage Collection

Typ-Deskriptor Zweck

- Ancestor Table für Typ-Test & Cast
- Virtual Method Table für Dynamic Dispatch
- Interpreter Metadata bei Field- / Array Typen
- **Neu:** Pointer Offsets für Garbage Collection

10.1 Explizite Freigabe

- Delete Statement zum Deallozieren eines Objektes

10.1.1 Probleme

- Dangling Pointers: Referenz auf gelöscht Objekt
- Memory Leaks: Verweiste Objekte, die nicht abräumbar sind

10.1.2 Dangling Pointer

- Zeigt auf Lücke oder falsches Objekt im Heap
- Lese nicht berechtigten Speicher (Security Issue)
- Überschreibe fremden Speicher (Safety + Security Issue)

10.1.3 Memory Leak

- Unbenötigtes Objekt, das nicht löschar ist
- Es gibt keine benutzbaren Referenzen mehr darauf

10.2 Garbage Collection

- Laufzeitsystem kümmert sich um die automatische Freigabe von Garbage
- Garbage = Objekte, die nicht mehr erreichbar sind und daher nicht mehr gebraucht werden

Ziel:

- Memory Safety
- Keine Dangling Pointers
- Keine Memory Leaks

10.2.1 Reference Counting

- RC pro Objekt
- Anzahl eingehender Referenzen
- Zyklische Objektstrukturen werden mit Reference Counting nie zu Garbage

Vorteil

- Sofortige Deallokation

Nachteile

- Falsch bei Zyklen
- Ineffizient

Untauglich

10.2.2 Transitive Erreichbarkeit

- Objekte beibehalten, die das Programm noch zugreifen könnte
- Ausgehend von Ankerpunkten (Root Set)

Root Set

- Referenzen in statischen Variablen
- Referenzen in Activation Frames auf Call Stack
- Referenzen in Register

10.3 Mark & Sweep Algorithmus

Mark Phase

- Markiere alle erreichbaren Objekte

Sweep Phase

- Lösche alle nicht markierten Objekte

10.3.1 Mark Phase

```
private void mark() {
    for(var root: getRootSet(stack)) {
        traverse(root);
    }
}

private void traverse(Pointer current) {
    if(current == null) {
        return;
    }
    long block = heap.getAddress(current) - Heap.BLOCK_HEADER_SIZE;
    if(!isMarked(block)) {
        setMark(block);
        for(var next: getPointers(current)) {
            traverse(next);
        }
    }
}
```

10.3.2 Rekursive Traversierung

- GC braucht zusätzlich Speicher für Stack
- Problematisch, da Speicher bei GC meist sowiso knapp ist
- Es existieren Algorithmen zur Traversierung ohne Zusatzspeicher (Pointer Rotation Algo)

10.3.3 Sweep Phase

- Linearer Scan über den gesamten Heap, alle Blöcke

```
private void sweep() {
    var current = Heap.HEAP_START;
    while(current < Heap.HEAP_SIZE) {
        if(!isMarked(current) && !freeList.contains(current)) {
            free(current);
        }
        clearMark(current);
        current += heap.getBlockSize(current);
    }
}
```

```
private void free(long address) {
    freeList.add(address);
}
```

10.4 Ausführungszeitpunkt

Delayed Garbage Collection

- Garbage wird nicht sofort erkannt und freigegeben
- GC läuft spätestens, wenn der Heap voll ist (Check beim Allozieren)
- Eventuell prophylaktisch früher

10.5 Stop & Go

- GC läuft sequentiell und exklusiv
- Mutator = Produktives Programm
- Mutator ist während GC unterbrochen



10.6 Root Set Erkennung

Pointer auf dem Call Stack

- Pointers in Parameter
- Pointers in lokalen Variablen
- Pointers auf Evaluation Stack
- this-Referenz

10.7 Pointers im Objekt

```
private Iterable<Pointer> getPointers(Pointer current) {
    var list = new ArrayList<Pointer>();
    var descriptor = heap.getDescriptor(current);
    if(descriptor instanceof ClassDescriptor classDescriptor) {
        var fields = classDescriptor.getAllFields();
        for(var i = 0; i < fields.length; i++) {
            var type = fields[i].getType();
            if(isPointerType(type)) {
                var value = heap.readField(current, i);
                if(value != null) {
                    list.add((Pointer) value);
                }
            }
        }
    } else if (descriptor instanceof ArrayDescriptor arrayDescriptor) {
        var length = heap.getLength(current);
        for (int i = 0; i < length; i++) {
            var value = heap.readElement(current, i);
            var type = arrayDescriptor.getElementType();
            if (value != null && isPointerType(type)) {
                list.add((Pointer) value);
            }
        }
    }
    return list;
}


private boolean isPointerType(Object pointer) {
    return pointer instanceof ClassDescriptor || pointer instanceof ArrayDescriptor;
}
```

10.8 Free List

- Freie Blöcke linear verketteten


### 10.8.1 Neue Heap Allokierung

- Traversiere Free List bis zu passendem Block
- Überschuss des Blockes wieder in free List einreihen



### 10.8.2 Heap Block Layout

#### Objekt-Block



#### Freier Block



### 10.8.3 Strategien

#### First Fit

- Keine Sortierung
- Suche erst passenden Block

#### Best Fit

- Nach aufsteigender Grösse sortiert
- Unbrauchbar kleine Fragmente

#### Worst Fit

- Nach absteigender Grösse sortiert
- Finde passenden Block sofort

#### Segregated Free List

- Mehrere Free Lists mit verschiedenen Grössenklassen
- e.g. 64..128, 128..196, 196..259, ...

#### Benachbarte freie Blöcke verschmelzen

- Am einfachsten in der Sweep Phase

#### Buddy System

- Diskrete Blockgrössen nach Adresse geordnet
- Exponentielle Blockgrösse
- Sehr schnelles Verschmelzen & Allokieren & Freigabe
- Aber grosse interne Fragmentierung (unbrauchbare Reste)

## 11 GC Vertiefung

#### Pointers in C++

- expliziter Zahlenwert
- Jedes Wort kann Pointer sein
- Keine GC Metadaten in C/C++

### 11.1 Finalizer

- Methode, die vor Löschen des Objektes läuft (Abschlussarbeit wie z.B. Verbindung schliessen)
- Von GC initiiert, wenn Objekt Garbage geworden ist

```
class Block {
    @Override
    protected void finalize() {
        // ...
    }
}
```

#### 11.1.1 Separate Finalisierung

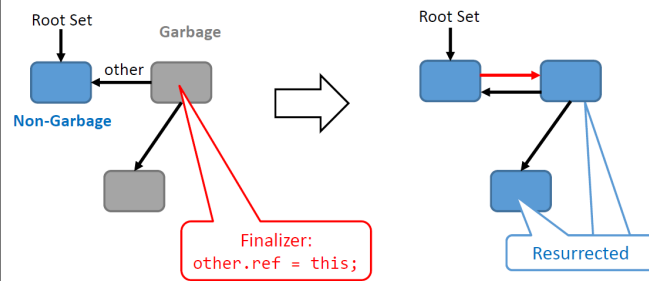
- Finalizer wird nicht in GC-Phase ausgeführt, sondern erst später

#### Gründe

- Finalizer dauert evtl. beliebig lange (blockiert sonst GC)
- Finalizer kann neue Objekte allozieren (korrumpiert GC)
- Programmierfehler im Finalizer (evtl. Crash des GC)
- Finalizer kann Objekt wieder weiterleben lassen (Resurrection)

### 11.1.2 Resurrection

- Finalizer kann bewirken, dass Objekt wieder lebendig wird und kein Garbage mehr ist
- Nicht nur das eigene Objekt, sondern auch indirekt andere Objekte können wiederauferstehen



### 11.1.3 Internals

#### Finalizer Set

- Registrierte Finalizer

#### Pending Queue

- Noch auszuführende Finalizer
- Garbage mit Finalizer werden in Pending Queue eingetragen
- Einfügen bewirkt Resurrection: Neue GC Phase nötig

### 11.1.4 Konsequenzen

#### GC braucht 2 Mark Phasen

- Markiere und erkenne Garbage mit Finalizer
- Markiere von Pending Queue erneut, dann Sweep

#### Objekt mit Finalizer braucht min 2 GC Durchläufe bis zur Freigabe

- Speicher kann evtl. nicht schnell genug frei werden

### 11.1.5 Programmieraspekte

- Reihenfolge der Finalizer ist unbestimmt
- Laufen beliebig verzögert
- Sind nebenläufig zum Hauptprogramm

### 11.2 Weak Reference

- Zählt nicht als Referenz für GC
- Für Objekt Caches

#### Internals


- Indirektion via Weak Reference Table
- GC Mark ignoriert Table-Einträge
- GC Sweep nullt Einträge, falls Zielobjekte gelöscht

### 11.3 Externe Fragmentierung

#### Viele kleine Lücken im Heap durch Allokieren & Free


- Spätere grössere Allokation passt in keine Lücke
- Obschon Summe der freien Blöcken genügend wäre

Neuer benötigter Speicher




### 11.4 Compacting GC

- Auch Mark & Copy GC
- Allokation am Heap-Ende (supereffizient)
- GC schiebt Objekte wieder zusammen
- Bei Verschieben müssen Referenzen nachgetragen werden
- Konservative Methode daher unmöglich (C/C++ nicht möglich)



### 11.5 Inkrementeller GC

- GC soll quasi-parallel zum Mutator laufen
- Nur kleinste Unterbrüche (Inkremments)
- Kein Stop & Go / Stop the World



#### 11.5.1 Generational GC

##### Zeitspiegelungsheuristik

- Junge Objekte: kurze Lebensdauer
- Alte Objekte: lange Lebensdauer

Alter	Generation	GC-Frequenz	GC Pause
neu	G0	hoch	kurz
mittel	G1	mittel	mittel
alt	G2	tief	lang

##### Root Sets bei Generationen


- Referenzen von alten zu neuen Generationen: Zusätzlicher Root Set der neuen Gen
- Write Barriers: Schreiben von Referenzen in alte Generationen erkennen
- Bei GC der alten Generationen müssen auch neuere mit aufgeräumt werden

#### 11.5.2 Partitioned GC

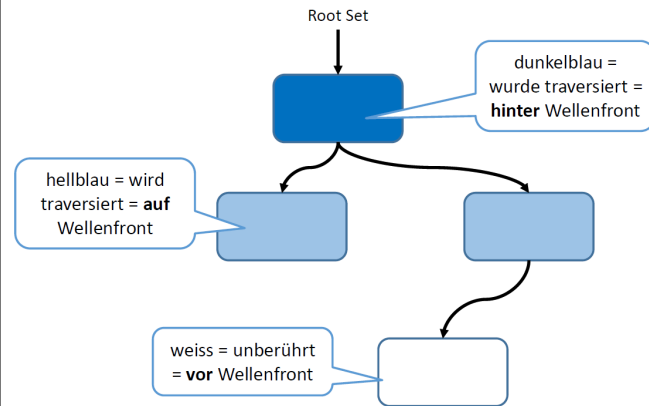
- Heap in Partitionen zerlegen
- Ziel: kurze GC Pausen
- Nebenläufiges Markieren mit Snapshots: Relevante nebenläufige Updates erkennen
- GC fokussiert auf Partitionen mit viel Garbage
- Evakuieren lebende Objekte in neue Partitionen

##### Problem

- Zyklischer Garbage zwischen Partitionen
- Braucht immer noch Full GC (Stop the World)




#### 11.6 Wellenausbreitungsmodell



#### 11.7 Isolationsproblem

- Referenzzuweisung durch Mutator während GC
- Kritisch: Neue Referenz von dunkelblau zu weiss
- **Heilung:** Quelle oder Ziel hellblau färben (Write Barrier)



12 Just-In-Time Compiler

- Effizientere Ausführung als Interpretation
- Bytecode direkt in nativen Prozessor-Code übersetzen und ausführen
- Nicht unbedingt alles, sondern nur kritische Teile

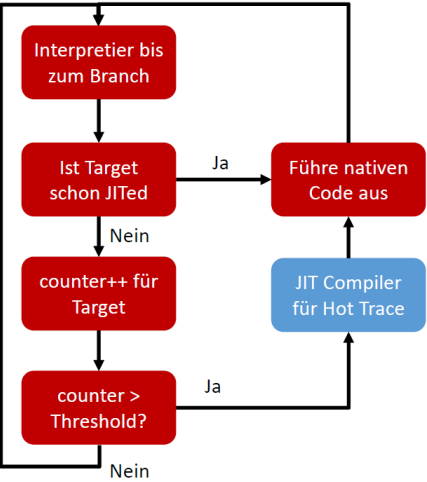
12.1 Hot Spot

- Performance-kritischer Code Abschnitt
- Wird häufig ausgeführt
- JIT-Kompilierung lohnt sich hierfür am meisten

12.2 Profiling

- Interpreter zählt Ausführung gewisser Code-Teile (Methoden, Traces (Code-Pfade))
- Falls häufig ausgeführt, JIT für den Teil anwerfen

12.3 Vorgehen




12.4 Intel 64 Architektur

Spezielle Register

- RSP: Stack Pointer
- RBP: Base Pointer
- RIP: Instruction Pointer

RAX
RBX
RCX
RDY
RSI
RDI
R8
...
R15



12.4.1 Elementare Instruktionen

ADD RAX, RBX	RAX += RBX
SUB RAX, RBX	RAX -= RBX
IMUL RAX, RBX	RAX *= RBX
IDIV RBX	RDX muss vorher 0 sein bei nicht-negativen RAX, sonst -1. RAX /= RBX, RDX = RAX % RBX

Signed Mul und Div

IDIV benutzt fixe Register (Register Clobbering)

MOV RAX, 100	Setze 100 in Register RAX
MOV RAX, RBX	Kopiere RBX in RAX

12.4.2 IDIV Vorbereiten

- Fixe 128-bit Division von RDX:RAX
- Setze RDX je nach RAX
  - 0 falls RAX >= 0
  - -1 falls RAX < 0

CDQ	Vorzeichenbehaftete Konversion von RAX nach RDX:RAX (Convert to Quad Word)
-----	--

12.5 Register Allokation

Lokale Register Allokation

- Für Ausdrucksauswertung (Evaluation Stack)
- Evaluation Stack Einträge auf Register abbilden
- Cross Compiler führt Stack an belegten Register
- Pro übersetzte Bytecode-Instruktion wird Stack nachgeführt

Globale Register-Allokation

- Variablen in Register speichern
- Deutlich schneller als Speicherzugriffe


Registeranzahl ist beschränkt!

12.6 Register Clobbering

- Evakuieren in neues Register bei Instruktionen mit fixem Operand (z.B. IDIV)

12.6.1 Register Relocation

- Umkopieren in anderes Register



12.7 Intel Branches

- Bedingte Sprünge basierend auf Condition Code
- Condition Code aus vorherigem Vergleich

CMP reg1, reg2	Compare
JE label	Jump if equal
JNE label	Jump if not equal
JG label	Jump if greater (reg1 > reg2)
JGE label	Jump if greater equal (reg1 >= reg2)
JL label	Jump if less (reg1 < reg2)
JLE label	Jump if less (reg1 <= reg2)
JMP label	Unconditional jump